

BLOC 6 — DIRECTION DE PROJET DATA

Bank Marketing Insights

Optimiser une campagne de télémarketing bancaire
grâce à un modèle prédictif

Isaac — Direction du projet, infrastructure & machine learning

Certification CDSD — RNCP35288 — Bootcamp Fullstack Data Science, Jedha

Le problème métier

Pourquoi c'est un problème

Les campagnes de télémarketing bancaire coûtent cher en temps et en ressources. Appeler l'intégralité d'une base de données clients pour proposer un produit — ici, un dépôt à terme — génère de la frustration chez les clients non intéressés et un coût d'acquisition (CAC) très élevé pour la banque.

L'objectif

Comment identifier en amont les clients ayant la plus forte probabilité de souscrire, afin de cibler les appels et maximiser le ROI de la campagne ?


45 211

clients dans le jeu de données

11,7 %

taux de conversion global observé

Répartition des souscriptions



Cadrage du projet

Objectifs, périmètre, planning, budget et conformité



Objectifs & périmètre

Projet fil rouge de fin de formation (Bootcamp Fullstack Data Science, Jedha).
Contrainte : dataset public (UCI Bank Marketing, 45 211 lignes), délai fixé par le calendrier du bootcamp. Livré : EDA, modélisation prédictive, dashboard de pilotage et simulateur commercial, déployés en production.



Rétroplanning (jalons réels)

10/02 Kickoff & setup → 11-12/02 Environnement & EDA → 17-18/02
Modélisation & intégration → 03/03 Finalisation & Demoday → Juin 2026
Reprise solo (infrastructure & maintenance).



Budget indicatif

Infrastructure quasi gratuite (tiers gratuits AWS S3, Streamlit, Hugging Face).
Coût principal : temps humain. Le modèle déployé génère un profit estimé de +41 610 € sur la base de test — le projet s'autofinance largement.



Conformité RGPD

Dataset public anonymisé (UCI), aucune donnée directement identifiante. Clés AWS individuelles par collaboratrice (principe de moindre privilège), .env exclu du versioning, hébergement en région UE (Paris).

Stack technique : Python · Pandas · Scikit-Learn · AWS S3 · Streamlit · Docker · Hugging Face

Pilotage & mon rôle

Direction du projet, de l'infrastructure à l'arbitrage méthodologique



Gouvernance technique

Création et administration du dépôt GitHub, gestion de l'ensemble des push/pull et résolution des conflits, formation de l'équipe à Git en cours de projet.



Infrastructure cloud

Conception de l'architecture AWS (buckets S3, IAM), création d'accès individuels par collaboratrice, sécurisation des identifiants (.env non versionné).



Arbitrage méthodologique

Après un essai sur une baseline, la modélisation a été reprise et fiabilisée pour livrer un modèle robuste, corrigé de sa fuite de données et de son sur-apprentissage.

Données & analyse exploratoire

Le jeu de données

45 211 clients — Bank Marketing (UCI Machine Learning Repository)

17 variables : âge, métier, statut, solde bancaire, prêts, historique de contact...

- Déséquilibre fort : seulement 11,7 % de souscription au dépôt à terme.
- Les profils seniors et jeunes actifs convertissent au-dessus de la moyenne.
- Mars, Septembre et Octobre : meilleurs taux de conversion, malgré un volume d'appels bien inférieur à Mai.



Démonstration en direct

Dashboard Streamlit (Hugging Face)
Exploration interactive du profil client

Machine Learning : de la baseline au modèle rentable

Progression du modèle

Baseline — Logistic Regression

Accuracy 76,2 % · F1 38 % · Precision 27,7 % · Recall 60,5 % · AUC 74 %

Modèle retenu — Random Forest régularisé


Train 81,95 % · Test 81,69 % · Écart 0,26 % (contre ~10 % avant régularisation)

Variable duration retirée : fuite de données détectée par corrélation.

Matrice de confusion (modèle retenu)

	Prédit: Non	Prédit: Oui
Réel: Non	6 821	1 164
Réel: Oui	492	566

Arbitrage business : seuil de décision



+41 610 €

profit estimé au seuil optimal (0,10), sur score calibré

Hypothèses de simulation : coût d'appel ≈ 10 €, gain par vente ≈ 100 €. Ordres de grandeur retenus pour illustrer la méthode d'arbitrage précision/recall — pas des chiffres réels de la banque.

Simulateur de prédiction

Traduire le score en priorité commerciale

Un score, trois priorités



Priorité basse

Moins de 10 % de chances de souscrire.



Client indécis

Score intermédiaire : argumentaire personnalisé requis.



Priorité haute

Forte probabilité : conclure rapidement.

Le score du modèle se traduit directement en recommandation commerciale : type d'argumentaire, niveau de suivi, priorité d'appel — pour accompagner les équipes de vente à chaque contact.



Démonstration en direct

Simulateur Streamlit (Hugging Face)
Scoring d'un client en temps réel

Bilan & perspectives

Ce que ce projet démontre

Efficacité chirurgicale

Ciblage précis fondé sur une probabilité de conversion robuste, plutôt qu'un marketing de masse.

Rentabilité pilotée

Le seuil de décision intègre directement les contraintes financières réelles (coût vs marge).

Productivité commerciale

Réduction des appels inutiles, temps commercial réalloué vers les clients les plus qualifiés.

Perspectives

Systématiser le pipeline de données

Automatiser l'ingestion des nouvelles campagnes dans S3, valider les nouvelles catégories, détecter la dérive des données.

Continuous learning

Réinjecter les résultats d'appels réels pour réentraîner le modèle régulièrement.

Optimisation temporelle

Identifier le meilleur moment (saisonnalité) pour déclencher chaque campagne.

Coûts & gains paramétrables

Rendre le coût d'appel et le gain par vente modifiables dans le simulateur, pour que chaque campagne recalcule son propre seuil optimal.

Merci.